

Statistički praktikum 1 - 36. zadatak

Hermina Petric Maretić

22. siječnja 2014.

Opis zadatka


- List indijanske penjačice može biti šaren ili jednoličan, te istovremeno blijed ili normalne boje.
- Postavljeno je pitanje jesu li te dvije karakteristike nezavisne.
- Prijašnji eksperimenti su pokazali da će mladica s vjerojatnosti $1/4$ biti blijeda (a normalne boje s vjerojatnosti $3/4$). Isto tako lišće mladica će s vjerojatnosti $1/4$ biti šareno (a s vjerojatnosti $3/4$ jednolično).
- Na slučajan način prikupljen je uzorak od 290 mladica indijske penjačice.

	normalne boje	blijedo
jednolično	187	35
šareno	37	31


(a) zadatak

- Neka je X stanje prve karakteristike (šareno ili lišće jednolične boje), a Y stanje druge karakteristike (blijedo lišće ili normalne boje).
- Na osnovi danog uzorka, procijenite zajedničku razdiobu varijabli X i Y , tj. procijenite razdiobu vektora (X,Y) i grafički je predstavite.
- Također, grafički je usporedite s razdiobom u kojoj su X i Y nezavisne, a marginalne razdiobe su u skladu s prijašnjim saznanjima.

Razdioba vektora (X,Y)



Usporedba procijenjene i nezavisne razdiobe



(b) zadatak

- Testirajte da li su X i Y nezavisne s pretpostavljenim marginalnim razdiobama kao u tekstu zadatka.
- Postavljamo hipoteze:
- $H_0 = X$ i Y su nezavisne s pretpostavljenim marginalnim razdiobama
- $H_0 = X$ i Y nisu nezavisne s pretpostavljenim marginalnim razdiobama
- Za testiranje koristimo Pearsonov χ^2 -test o pripadnosti distribuciji s testnom statistikom

$$H = \sum_{i=1}^r \sum_{j=1}^c \frac{(f_{i,j} - f'_{i,j})^2}{f'_{i,j}} \sim \chi^2(r * c - d - 1)$$

(b) zadatak

- Kritično područje: $[7.815, \infty)$
- Vrijednost testne statistike: $h=25.096$
- Odbacujemo nultu hipotezu na razini značajnosti od 5%
- P-vrijednost: $1.47 * 10^{-5}$

(c) zadatak

- Odredite jakost testa iz (b) uz značajnost 5%
- Postavljamo hipoteze:
- $H_0 : p = p^{(0)}$
- $H_1 : p = p^{(0)} - \frac{1}{\sqrt{n}}\delta$, za neki $\delta \neq 0$

(c) zadatak

- Testna statistika je

$$H = \sum_{i=1}^r \sum_{j=1}^c \frac{(f_{i,j} - f'_{i,j})^2}{f'_{i,j}} \sim \chi^2(r * c - d - 1)$$


- Ako vrijedi hipoteza H_1 , tada je $H \sim A_{\chi^2}(k - 1, \lambda)$, gdje je

$$\lambda = \sum_{k=1}^k \frac{\delta_i^2}{p_i^0} \text{ parametar necentralnosti.}$$

- Tada funkciju jakosti Pearsonovog χ^2 -testa možemo prikazati ovako:

$$\gamma(\lambda) = P(H \geq \chi^2(k - 1) | p = p^0 - \frac{1}{\sqrt{n}} * \delta) = \\ 1 - P_{\chi^2(k-1, \lambda)}(\chi^2_{\alpha}(k - 1))$$

(c) zadatak



- Minimum se postiže u točki 0 i iznosi 0.05. To proizlazi iz činjenice da hipoteza H_0 govori upravo da je $\lambda = 0$ i iz činjenice da test ima razinu značajnosti 5%.

(d) zadatak

- Prema jednoj drugoj teoriji, razdioba od (X,Y) je oblika

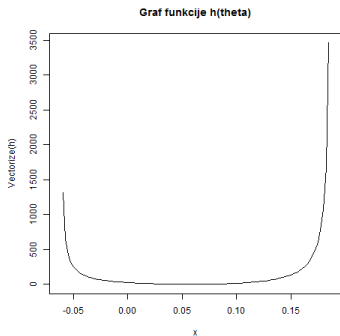
X Y	normalne boje	blijedo
jednolično	$9/16 + \theta$	$3/16 - \theta$
šareno	$3/16 - \theta$	$1/16 + \theta$

gdje je θ nepoznati parametar. Odredite parametarski prostor i pomoću χ^2 -testa testirajte tu hipotezu, pri čemu nepoznati parametar procjenite minimum χ^2 -metodom.

(d) zadatak

- Parametarski prostor: $\theta \in [-1/16, 3/16]$
- Minimum χ^2 -metoda se temelji na tome da za funkciju
$$h(\theta) : \Theta \rightarrow R, h(\theta) = \sum_{i=1}^k \sum_{j=1}^c \frac{(f_{i,j} - f'_{i,j}(\theta))^2}{f'_{i,j}(\theta)}$$
 tražimo
vrijednost $\hat{\theta}$ u kojoj ona postiže minimum.

(d) zadatak



- Kao što i otprilike vidimo na grafu, minimum se postiže u točki 0.0586, pa je baš to naš $\hat{\theta}$.

(d) zadatak


- Testiramo hipotezu da je razdioba našeg slučajnog vektora iz zadanog modela
- Iskoristimo procijenjeni parametar θ i provodimo χ^2 -test s 2 ($d=1$ jer imamo jedan procijenjeni parametar) stupnja slobode.
- P-vrijednost: 0.6371446
- P-vrijednost je velika, pa ne možemo odbaciti hipotezu o pripadnosti zadanom modelu.

(e) zadatak

- Procijenite nepoznati parametar iz modela u (d) metodom maksimalne vjerodostojnosti i usporedite ga s minimum χ^2 -procjenom
- Definiramo funkciju vjerodostojnosti $L : \Theta \rightarrow R$, sa $L(\theta) = \prod_{i=1}^n f(x_i|\theta)$. Tražimo θ koji maksimizira ovu funkciju i zovemo ga procjenom metodom maksimalne vjerodostojnosti.


(e) zadatak

Graf derivacije funkcije vjerodostojnosti



- $\hat{\theta} = 0.05840407$

(e) zadatak



Hvala na pažnji!